

UNIVERSITÀ DEGLI STUDI DI MILANO
FACOLTÀ DI SCIENZE E TECNOLOGIE

DIPARTIMENTO DI INFORMATICA
GIOVANNI DEGLI ANTONI



Corso di Laurea triennale in Informatica

PATTERN DI ASSEGNAIMENTO OTTIMIZZATI PER
L'EFFICIENZA ENERGETICA IN EDGE COMPUTING

Relatore: Prof. Alberto Ceselli
Correlatore: Prof. Marco Premoli

Tesi di Laurea di:
Manuel Parati
Matr. 958584

ANNO ACCADEMICO 2021-2022

Ringraziamenti

Questa sezione, contiene i ringraziamenti.

Indice

Ringraziamenti	i
Indice	ii
1 Introduzione	1
1.1 Obbiettivi	1
1.2 Struttura dell'elaborato	1
2 Modellazione del sistema	2
2.1 L'infrastruttura Mobile Edge Computing	2
2.2 Modello di orchestrazione proposto	3
2.2.1 Esempio del funzionamento	4
2.2.2 Implementazione	5
3 Modelli di ottimizzazione	7
3.1 Modello di assegnamento dinamico	7
3.2 Modello di assegnamento statico	9
3.2.1 Variante con quadro energetico completo	11
3.3 Modello di assegnamento singolo time-slot	12
4 Algoritmi euristici	14
4.1 Semplificazione del modello	14
4.2 Aggregamento dei time-slot	14
Bibliografia	15

Capitolo 1

Introduzione

...

1.1 Obbiettivi

...

1.2 Struttura dell'elaborato

...

Capitolo 2

Modellazione del sistema

Questo capitolo fornisce una panoramica riguardo all'infrastruttura Mobile Edge Computing ed illustra il modello di orchestrazione proposto in questo lavoro.

2.1 L'infrastruttura Mobile Edge Computing

All'interno di un'infrastruttura Mobile Edge Computing (MEC) si trovano i cluster di virtualizzazione, spesso noti come 'MEC facility' o più semplicemente 'facility', e gli access point (AP). Le facility sono il luogo in cui avviene la virtualizzazione e sono composte dalle macchine virtuali (VM) su cui si eseguono le applicazioni degli utenti finali, mentre gli AP sono i dispositivi (per esempio le antenne wireless) a cui gli end point si collegano per poter ricevere il servizio. Ogni AP è associato ad una facility, a cui inoltra tutto il traffico che riceve: questo significa che ogni facility avrà in esecuzione nelle proprie VM tutte le applicazioni utilizzate dagli utenti connessi agli AP a lui associati. Ogni facility, per poter gestire il traffico che le viene inoltrato, deve utilizzare una quantità di energia direttamente proporzionale a tale domanda. Per questo motivo, ognuna di esse possiede dei pannelli fotovoltaici che generano una quantità di energia variabile nel tempo, dipendente dal numero di pannelli installati e dall'irraggiamento a cui sono sottoposti. L'energia prodotta può essere direttamente utilizzata oppure immagazzinata all'interno di alcune batterie, dotate di capacità limitata. Nel caso in cui l'energia disponibile, data dalla somma tra quella accumulata e quella generata, non basti a soddisfare la domanda, è possibile acquistarne altra ad un prezzo dipendente dalla facility e dall'istante temporale.

Data la natura mobile degli end point, che sono per esempio smartphone o laptop, il traffico a cui sono sottoposti gli AP varia nel tempo e di conseguenza cambia la domanda rivolta alle facility. Per questo motivo l'assegnamento viene effettuato

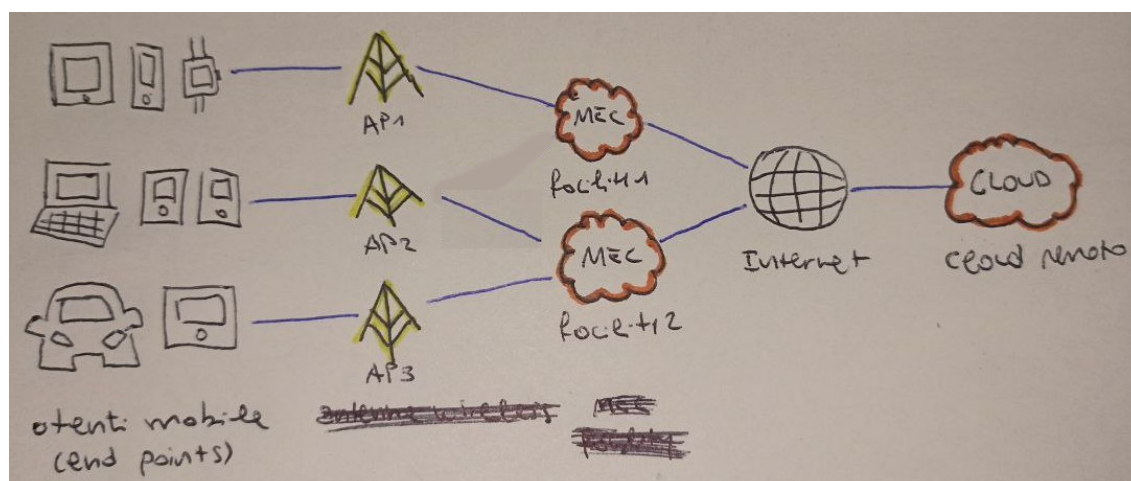


Figura 1: Esempio di un'infrastruttura Mobile Edge Computing (MEC).

dinamicamente, e lo strumento incaricato di svolgere tale compito è l'orchestratore, che implementa la logica definita dal modello di orchestrazione. Le azioni che svolge vengono chiamate 'orchestrazioni' o 'switch' e consistono nell'assegnare un AP ad una facility diversa da quella attuale, provocando il ridimensionamento della potenza delle VM in termini del numero di processori e memoria disponibile, e la migrazione del loro stato. Il ridimensionamento è dovuto alla variazione di domanda da gestire, mentre la migrazione dello stato è necessaria per avere in esecuzione in ogni facility le applicazioni utilizzate dagli utenti connessi agli AP che le sono assegnati. Il costo prodotto dalla migrazione prende il nome di 'costo di migrazione'.

Nella Figura 1 è presente un'infrastruttura MEC composta da due facility e tre AP, a cui sono collegati diversi dispositivi mobili di vario genere. Si noti come ogni dispositivo invii il proprio traffico all'AP a cui è collegato, e come tutto il traffico ricevuto da ogni AP sia inoltrato alla stessa facility. Si può osservare, per esempio, come al secondo AP siano connessi un laptop e due smartphone, mentre al terzo un'automobile smart ed un tablet. Nella figura i due AP sono assegnati alla stessa facility (la seconda) che riceverà e dovrà quindi gestire il traffico di tutti e cinque i dispositivi. Si noti infine come sia presente un cloud centralizzato che gestisce e sincronizza le varie facility.

2.2 Modello di orchestrazione proposto

Il modello di orchestrazione proposto rappresenta una variante di quello presentato negli articoli [1] e [2], in cui nell'effettuare le scelte di orchestrazione si tiene in




Figura 2: Esempio funzionamento del modello di orchestrazione.

considerazione anche l'utilizzo dell'energia da parte delle facility.

Come illustrato in [2], all'interno del modello viene introdotta una discretizzazione temporale che permette di effettuare migrazioni solo in determinati istanti, per esempio ogni 15 minuti. Questa scelta è ragionevole, dato che in caso contrario si pagherebbe un costo troppo elevato in termini di migrazione e spese generali dovute alla gestione del traffico. L'orizzonte temporale viene quindi rappresentato da un insieme di time-slot della stessa durata.

L'obiettivo del modello è quello di effettuare assegnamenti che permettano di raggiungere un buon compromesso tra: ottenere una buona qualità del servizio (cioè bassa latenza per l'utente finale), costi di migrazione contenuti e buona gestione dell'energia da parte delle facility. Nell'effettuare le scelte bisogna tenere in considerazione che la domanda degli AP e l'energia prodotta dalle facility varia nel corso del tempo, e che ogni facility possiede un limite massimo di domanda che è in grado di soddisfare simultaneamente e una quantità di energia limite che può mantenere nello stesso momento all'interno delle proprie batterie. Si supponga inoltre che le facility, per gestire una unità di traffico, debbano utilizzare una unità di energia.

2.2.1 Esempio del funzionamento

Una semplice applicazione di esempio è presentata nella Figura 2. Come si può osservare, è presente una rete MEC con due facility (K1 e K2) e quattro AP (A, B, C, D) considerata in due time-slot consecutivi ($t=0, 1$). Gli end point connessi agli AP sono rappresentati con dei piccoli cerchi, e si supponga che inizialmente

le batterie siano vuote in entrambe le facility. Nel primo time-slot ($t=1$) gli AP A e B sono associati alla facility K1 mentre C e D a K2, quindi tutti gli utenti che sono connessi ad A e B avranno le proprie applicazioni in esecuzione su una VM presente in K1, mentre quelli connessi a C e D le avranno in K2. Questi assegnamenti permettono di avere una buona latenza dato che ogni AP è connesso alla facility più vicina, ma anche una buona gestione energetica, in quanto nella facility K1 vengono prodotte 10 unità di energia ed utilizzate solo 7 mentre in K2 se ne producono 11 e utilizzano 9. In entrambi i casi avanzano delle unità (3 in K1 e 2 in K2) che vengono immagazzinate nelle batterie per poter essere spese nei prossimi time-slot. Successivamente tre utenti connessi all'AP B si spostano e si agganciano a C: a questo punto K2 riceve una richiesta di domanda eccessiva che non riesce a gestire e di conseguenza è necessario effettuare un'orchestrazione per ribilanciare il traffico. Questo comporta l'assegnare C a K1, ridimensionare le VM (aumentarne la potenza in K1 e diminuirla in K2) e sincronizzare le facility trasferendo lo stato delle VM riguardanti tutti gli utenti connessi a C da K2 a K1. In un contesto reale, il modello deve prevenire una situazione di questo tipo effettuando orchestrazioni che tengano in considerazione la futura domanda dei vari AP, dato che questa circostanza va ad inficiare la qualità complessiva del servizio. Nel secondo time-slot ($t=2$) si avranno quindi gli AP A, B e C assegnati alla facility K1, mentre D a K2. Dal punto di vista energetico, la facility K1 riesce a soddisfare la domanda di traffico (9 unità) utilizzando l'energia presente nella batteria e quella prodotta in questo time-slot ($8 + 3$ unità complessive). Per quanto riguarda invece K2, l'energia disponibile ($3 + 2$ unità) non è sufficiente e quindi è necessario acquistare una ulteriore unità. Da notare come l'energia potrebbe avere costi diversi nel corso dei time-slot, e di conseguenza potrebbe risultare conveniente acquistarla quando il costo è basso per immagazzinarla ed utilizzarla successivamente.

2.2.2 Implementazione

Il comportamento del modello di orchestrazione fin qui descritto viene implementato attraverso un modello di programmazione lineare chiamato 'modello di assegnamento dinamico' e descritto dettagliatamente nella sezione 3.1. Al modello viene fornita come input un'istanza del problema (formata da dati riguardanti l'infrastruttura MEC presa in considerazione e, per ogni time-slot, il traffico rivolto agli AP e la produzione di energia di ogni facility) e ritorna in output il piano degli assegnamenti ottimale. Questa rappresenta la miglior metodologia per risolvere il problema in quanto garantisce di ottenere la soluzione ottima, ma a causa della sua natura combinatoria potrebbe essere inutilizzabile in determinate situazioni. Infatti quando il numero di time-slot presi in considerazione oppure la quantità di AP o facility aumenta, il tempo di calcolo necessario ad arrivare alla soluzione ottima cresce esponenzialmente fino a diventare proibitivo. Per questo motivo

vengono successivamente proposte due euristiche, che semplificano il problema con l'obiettivo di abbassare la complessità del modello ed ottenere una soluzione non troppo peggiore rispetto a quella ottima. Nella sezione 4.1 viene presentata la prima idea euristica, che mira ad abbassare la complessità semplificando il modello utilizzato, mentre nella sezione 4.2 la seconda, che aggrega i time-slot dell'istanza per ottenerne una più facilmente risolvibile.

Capitolo 3

Modelli di ottimizzazione

In questo capitolo vengono introdotti i modelli di ottimizzazione utilizzati nel corso dell'elaborato. Nel primo sottocapitolo si illustra il modello di assegnamento dinamico rappresentante il problema descritto, mentre nei due successivi quelli utilizzati dagli algoritmi euristici: il modello di assegnamento statico ed il modello che effettua l'assegnamento utilizzando istanze composte da un solo time-slot.

3.1 Modello di assegnamento dinamico

Il 'modello di assegnamento dinamico' è un modello di programmazione lineare misto-intera (MILP) che, considerata un'infrastruttura MEC, è in grado di definire dinamicamente gli assegnamenti AP-facility all'interno di un arco temporale in cui sono noti i livelli di traffico rivolti agli AP e l'energia prodotta dalle facility, per ogni time-slot. Con 'dinamicamente' si intende la possibilità di assegnare lo stesso AP a facility differenti nel corso dei time-slot, permettendo di bilanciare nel tempo la domanda complessiva rivolta alle facility. Questo migliora la latenza complessiva e la gestione energetica attuata, ma provoca la necessità di dover gestire i vari switch e pagare i costi di migrazione. L'output del modello è un piano degli assegnamenti: viene indicato in ogni time-slot a quale facility della rete deve indirizzare il traffico ogni AP. Di conseguenza è possibile estrarre anche il piano delle orchestrazioni, che corrisponde ad un valore booleano per ogni time-slot, per ogni AP e per ogni coppia di facility, che assume come valore 'vero' se in quell'istante temporale l'AP effettua uno switch tra le facility considerate, altrimenti 'falso'.

Dati. Data un'infrastruttura MEC, siano A l'insieme degli AP e K l'insieme delle facility che la compongono. Si supponga inoltre di avere un orizzonte temporale discretizzato in un insieme di T time-slot. Vengono indicati, per ogni AP $i \in A$, con d_i^t la quantità di traffico a cui i è sottoposto al time-slot $t \in T$ e con $m_{i,k}$ la distanza

fisica tra i e la facility $k \in K$. La distanza di rete tra due facility $j, k \in K \times K$ è invece denotata con l_{jk} : tale valore è direttamente proporzionale alla loro distanza fisica ed alla latenza di rete, includendo anche il tempo necessario a processare i pacchetti all'interno dei nodi intermedi. Data una facility $k \in K$, siano: C_k la quantità di domanda che riesce a gestire contemporaneamente, G_k la capienza complessiva delle sue batterie, p_k l'energia inizialmente presente all'interno delle batterie, e_k^t l'energia che produce nel time-slot $t \in T$, e c_k^t il prezzo a cui può acquistare l'energia nel time-slot $t \in T$.

Variabili. Siano x_{ik}^t variabili binarie che assumono valore 1 nel caso in cui al time-slot $t \in T$ l'AP $i \in A$ è assegnato alla facility $k \in K$, altrimenti 0. Le variabili y_{ijk}^t sono anch'esse binarie e valgono 1 se l'AP $i \in A$ viene associato alla facility $j \in K$ al tempo $t - 1$ ed alla facility $k \in K$ al tempo t , altrimenti 0. Da notare come queste siano le variabili che indicano le orchestrazioni da effettuare. Per ogni facility $k \in K$ e time-slot $t \in T$, siano: g_k^t l'energia residua della facility k al tempo t (quindi quella che viene immagazzinata all'interno delle batterie e disponibile nel time-slot $t + 1$), v_k^t l'energia utilizzata dalla facility k al tempo t e z_k^t la quantità di energia acquistata dalla facility k al tempo t .

Modello. Di seguito la rappresentazione matematica del modello.

$$\min \quad \alpha \sum_{t \in T} \sum_{i \in A} \sum_{\substack{(j,k) \in \\ K \times K}} d_i^t l_{jk} y_{ijk}^t + \beta \sum_{t \in T} \sum_{i \in A} \sum_{k \in K} d_i^t m_{ik} x_{ik}^t + \gamma \sum_{t \in T} \sum_{k \in K} c_k^t z_k^t \quad (3.1.1)$$

$$\text{s.t.} \quad v_k^t = \sum_{i \in A} d_i^t x_{ik}^t \quad \forall k \in K, \forall t \in T \quad (3.1.2)$$

$$\sum_{k \in K} x_{ik}^t = 1 \quad \forall i \in A, \forall t \in T \quad (3.1.3)$$

$$x_{ik}^t = \sum_{l \in K} y_{ilk}^t \quad \forall i \in A, \forall k \in K, \forall t \in T \setminus \{1\} \quad (3.1.4)$$

$$x_{ik}^t = \sum_{l \in K} y_{ikl}^{t+1} \quad \forall i \in A, \forall k \in K, \forall t \in T \setminus \{T\} \quad (3.1.5)$$

$$z_k^1 + e_k^1 + p_k \geq v_k^1 + g_k^1 \quad \forall k \in K \quad (3.1.6)$$

$$z_k^t + e_k^t + g_k^{t-1} \geq v_k^t + g_k^t \quad \forall k \in K, \forall t \in T \setminus \{1\} \quad (3.1.7)$$

$$g_k^t \leq G_k \quad \forall k \in K, \forall t \in T \quad (3.1.8)$$

$$v_k^t \leq C_k \quad \forall k \in K, \forall t \in T \quad (3.1.9)$$

$$x_{ik}^t \in \{0, 1\} \quad \forall i \in A, \forall k \in K, \forall t \in T \quad (3.1.10)$$

$$y_{ik'k''}^t \in \{0, 1\} \quad \forall i \in A, \forall k', k'' \in K, \forall t \in T \quad (3.1.11)$$

$$x, y, g, v, z \geq 0 \quad (3.1.12)$$

Obbiettivo. La funzione obbiettivo (3.1.1) ha lo scopo di ottenere la soluzione che possiede il miglior bilanciamento tra avere una buona latenza per l'utente finale ed ottenere costi di migrazione e di acquisto dell'energia contenuti. In particolare, si vuole minimizzare la somma tra (nell'ordine) i costi complessivi di migrazione, la latenza complessiva e il costo globale di acquisto dell'energia, dove i parametri α , β e γ indicano quanto peso dare a ciascun componente.

Vincoli. I vincoli 3.1.2 determinano il valore delle variabili v_k^t : la domanda a cui è sottoposta la facility $k \in K$ al tempo $t \in T$ è data dalla somma del traffico proveniente da tutti gli AP che le sono assegnati in quel time-slot. I vincoli 3.1.3 impongono ogni AP ad essere assegnato esattamente ad una facility per time-slot. I vincoli 3.1.4 e 3.1.5 collegano le variabili x ed y e servono a gestire il flusso degli switch: quando x_{ik}^t vale 0 significa che l'AP $i \in A$ non è associato alla facility $k \in K$ e di conseguenza non permettono di effettuare nessuna orchestrazione, mentre nel caso contrario impongono di effettuarne esattamente una oppure mantenere l'AP i associato alla facility k . I vincoli 3.1.6 e 3.1.7 gestiscono il flusso dell'energia: impongono che per ogni time-slot e per ogni facility la quantità di energia disponibile (data dalla somma tra quella prodotta, quella presente nelle batterie e quella acquistata) sia non minore della somma tra la quantità utilizzata e quella che viene immagazzinata nelle batterie. I vincoli 3.1.8 e 3.1.9 limitano superiormente i valori che possono assumere rispettivamente le variabili g e v , facendo in modo che non venga sforata la capienza delle batterie e la capacità delle facility.

3.2 Modello di assegnamento statico

Il 'modello di assegnamento statico' è un modello di tipo MILP che ha lo stesso scopo del modello di assegnamento dinamico (3.1) ma con la differenza che non permette di effettuare switch. Ogni AP sarà quindi assegnato alla stessa facility per tutto l'arco temporale preso in considerazione, e non attuando migrazioni il costo di migrazione complessivo sarà 0. In generale, utilizzare un approccio di assegnamento dinamico fornisce minore latenza e migliore efficienza energetica complessive rispetto ad uno statico, in quanto è possibile adattare gli assegnamenti alla variazione del traffico richiesto dai vari AP ed alla quantità di energia prodotta dalle facility. La formulazione del problema statico è però più leggera rispetto alla controparte dinamica, infatti necessita di un numero inferiore di variabili e vincoli, con conseguente diminuzione della complessità combinatoria. L'output del modello in questo caso sarà una lista di assegnamenti validi per tutti i time-slot.

Dati. I dati su cui opera sono gli stessi del modello dinamico, si veda la sezione 3.1 per una panoramica completa.

Variabili. Siano x_{ik} variabili binarie che assumono valore 1 se l'AP $i \in A$ viene assegnato alla facility $k \in K$, 0 altrimenti. Per ogni facility $k \in K$ e per ogni time-slot $t \in T$ siano inoltre g_k^t l'energia residua della facility k al tempo t , v_k^t l'energia utilizzata dalla facility k al tempo t e z_k^t la quantità di energia acquistata dalla facility k al tempo t . Come si può notare, il set di variabili viene notevolmente ridotto rispetto al modello dinamico, in quanto imponendo assegnamenti statici non è più necessario gestire il flusso degli switch e memorizzare gli assegnamenti per ogni time-slot. Le variabili y diventano quindi superflue, e per determinare gli assegnamenti è sufficiente una variabile x per ogni coppia AP-facility.

Modello. Di seguito la rappresentazione matematica del modello.

$$\min \quad \beta \sum_{t \in T} \sum_{i \in A} \sum_{k \in K} d_i^t m_{ik} x_{ik} + \gamma \sum_{t \in T} \sum_{k \in K} c_k^t z_k^t \quad (3.2.1)$$

$$\text{s.t.} \quad v_k^t = \sum_{i \in A} d_i^t x_{ik} \quad \forall k \in K, \forall t \in T \quad (3.2.2)$$

$$\sum_{k \in K} x_{ik} = 1 \quad \forall i \in A \quad (3.2.3)$$

$$z_k^1 + e_k^1 + p_k \geq v_k^1 + g_k^1 \quad \forall k \in K \quad (3.2.4)$$

$$z_k^t + e_k^t + g_k^{t-1} \geq v_k^t + g_k^t \quad \forall k \in K, \forall t \in T \setminus \{1\} \quad (3.2.5)$$

$$g_k^t \leq G_k \quad \forall k \in K, \forall t \in T \quad (3.2.6)$$

$$v_k^t \leq C_k \quad \forall k \in K, \forall t \in T \quad (3.2.7)$$

$$x_{ik} \in \{0, 1\} \quad \forall i \in A, \forall k \in K \quad (3.2.8)$$

$$x, g, v, z \geq 0 \quad (3.2.9)$$

Obbiettivo. La funzione obbiettivo (3.2.1) ha lo scopo di determinare la soluzione che rappresenta il miglior compromesso tra ottenere una bassa latenza complessiva e un prezzo totale di acquisto dell'energia contenuto. I parametri β e γ corrispondono ai pesi da assegnare a ciascuna componente. Da notare come l'unica differenza con la funzione del modello normale (3.1.1) sia l'assenza della prima parte, riguardante i costi di migrazione.

Vincoli. I vincoli 3.2.2 determinano il valore delle variabili v_k^t : l'energia utilizzata dalla facility $k \in K$ al tempo $t \in T$ è data dalla somma del traffico proveniente da

ogni AP $i \in A$ che le è assegnato; mentre i vincoli 3.2.3 impongono ad ogni AP di essere associato esattamente ad una facility. I vincoli 3.2.4 e 3.2.5 riguardano la gestione ed il flusso dell'energia e sono equivalenti ai 3.1.6 e 3.1.7 del modello dinamico, mentre quelli rappresentati dalle disequazioni 3.2.6 e 3.2.7 impongono di non eccedere rispettivamente la capacità delle batterie e la capienza delle facility, e sono l'equivalente dei 3.2.8 e 3.2.9.

3.2.1 Variante con quadro energetico completo

Da notare come questo modello non garantisca di tracciare il reale flusso di energia che avviene all'interno delle facility, dato che per come sono posti i vincoli 3.2.4 e 3.2.5 ci potrebbero essere delle quantità di energia residua che non vengono accumulate in quanto non utilizzate nei time-slot successivi. Nel determinare la soluzione ottima questo non causa problemi, ma nei casi in cui si necessita di un quadro realistico della gestione energetica, è necessario apportare alcune modifiche. In particolare, si deve immagazzinare ogni volta tutta l'energia possibile, quindi i vincoli 3.2.4 e 3.2.5 vengono rispettivamente riformulati come:

$$z_k^1 + e_k^1 + p_k = v_k^1 + g_k^1 + s_k^1 \quad \forall k \in K \quad (3.2.10)$$

$$z_k^t + e_k^t + g_k^{t-1} = v_k^t + g_k^t + s_k^t \quad \forall k \in K, \forall t \in T \setminus \{1\} \quad (3.2.11)$$

dove s_k^t sono variabili non negative che indicano la quantità di energia non accumulabile nella facility $k \in K$ al tempo $t \in T$ a causa della capienza limitata delle batterie. La quantità di energia disponibile (data dalla somma tra quella acquistata, quella prodotta e quella presente nelle batterie) è posta quindi uguale alla somma tra la quantità utilizzata, la quantità accumulata e la quantità non accumulabile. A questo punto nella funzione obiettivo (3.2.1) è necessario minimizzare anche la somma complessiva dell'energia non accumulabile ($\sum_{t \in T} \sum_{k \in K} s_k^t$), trasformandola in:

$$\min \quad \beta \sum_{t \in T} \sum_{i \in A} \sum_{k \in K} d_i^t m_{ik} x_{ik} + \gamma \sum_{t \in T} \sum_{k \in K} c_k^t z_k^t + \sum_{t \in T} \sum_{k \in K} s_k^t \quad (3.2.12)$$

in modo tale da avere nelle variabili g il valore più alto possibile, e quindi immagazzinare ogni volta tutta la quantità possibile.

Di seguito la rappresentazione matematica completa:

$$\min \quad \beta \sum_{t \in T} \sum_{i \in A} \sum_{k \in K} d_i^t m_{ik} x_{ik} + \gamma \sum_{t \in T} \sum_{k \in K} c_k^t z_k^t + \sum_{t \in T} \sum_{k \in K} s_k^t \quad (3.2.12)$$

$$\text{s.t.} \quad v_k^t = \sum_{i \in A} d_i^t x_{ik} \quad \forall k \in K, \forall t \in T \quad (3.2.2)$$

$$\sum_{k \in K} x_{ik} = 1 \quad \forall i \in A \quad (3.2.3)$$

$$z_k^1 + e_k^1 + p_k = v_k^1 + g_k^1 + s_k^1 \quad \forall k \in K \quad (3.2.10)$$

$$z_k^t + e_k^t + g_k^{t-1} = v_k^t + g_k^t + s_k^t \quad \forall k \in K, \forall t \in T \setminus \{1\} \quad (3.2.11)$$

$$g_k^t \leq G_k \quad \forall k \in K, \forall t \in T \quad (3.2.6)$$

$$v_k^t \leq C_k \quad \forall k \in K, \forall t \in T \quad (3.2.7)$$

$$x_{ik} \in \{0, 1\} \quad \forall i \in A, \forall k \in K \quad (3.2.8)$$

$$x, g, s, v, z \geq 0 \quad (3.2.13)$$

Da notare come l'aggiunta delle variabili s renda questo modello leggermente più complesso rispetto a quello di riferimento, e che nel risolvere le stesse istanze si otterranno risultati della stessa qualità.

3.3 Modello di assegnamento singolo time-slot

Il 'modello di assegnamento singolo time-slot' è un modello di tipo MILP ottimizzato per definire gli assegnamenti all'interno di istanze composte da un singolo time-slot, e fornisce quindi in output la facility a cui deve indirizzare il traffico ogni AP nel time-slot considerato.

Dati. Data un'infrastruttura MEC, siano A l'insieme degli AP e K l'insieme delle facility che la compongono. Per ogni AP $i \in A$, vengono indicati con d_i la quantità di traffico a cui i è sottoposto e con m_{ik} la distanza fisica tra i e la facility $k \in K$. La distanza di rete tra due facility $j, k \in K \times K$ è invece denotata con l_{jk} : tale valore è direttamente proporzionale alla loro distanza fisica ed alla latenza di rete, incluso il tempo di processamento dei pacchetti nei nodi intermedi. Data una facility $k \in K$, siano: C_k la quantità di domanda che riesce a gestire contemporaneamente, p_k l'energia inizialmente presente all'interno delle sue batterie, e_k l'energia che produce, e c_k il prezzo a cui può acquistare l'energia.

Variabili. Gli assegnamenti sono rappresentati da variabili binarie x_{ik} , che assumono come valore 1 se l'AP $i \in A$ viene assegnato alla facility $k \in K$, altrimenti 0. Inoltre, data una facility $k \in K$, siano: z_k l'energia che acquista, v_k l'energia che utilizza e s_k l'energia residua al termine del time-slot.

Modello.

$$\min \quad \beta \sum_{i \in A} \sum_{k \in K} d_i m_{ik} x_{ik} + \gamma \sum_{k \in K} c_k z_k \quad (3.3.1)$$

$$\text{s.t. } v_k = \sum_{i \in A} d_i x_{ik} \quad \forall k \in K \quad (3.3.2)$$

$$\sum_{k \in K} x_{ik} = 1 \quad \forall i \in A \quad (3.3.3)$$

$$z_k + e_k + p_k = v_k + s_k \quad \forall k \in K \quad (3.3.4)$$

$$v_k \leq C_k \quad \forall k \in K \quad (3.3.5)$$

$$x_{ik} \in \{0, 1\} \quad \forall i \in A, \forall k \in K \quad (3.3.6)$$

$$x, s, v, z \geq 0 \quad (3.3.7)$$

Obbiettivo. La funzione obbiettivo (3.3.1) ha lo scopo di definire gli assegnamenti che rispecchiano il miglior trade-off tra l'ottenere una bassa latenza complessiva ed avere una spesa energetica contenuta. Da notare come prendendo in considerazione un singolo time-slot, non sia possibile effettuare switch e di conseguenza l'obbiettivo rispecchia quello presente nel modello di assegnamento statico (3.2.1).

Vincoli. I vincoli 3.3.2 definiscono il valore delle variabili v_k , mentre i 3.3.3 impongono di assegnare ogni AP ad esattamente una facility. I vincoli 3.3.4 gestiscono l'utilizzo dell'energia, mentre i 3.3.5 definiscono un limite superiore alla quantità di traffico che ogni facility può gestire. Da notare come in questo caso, trattandosi di un singolo time-slot, non viene tenuta in considerazione la possibilità di immagazzinare l'energia nella batterie, e quindi tutta quelle le quantità in eccesso saranno indicate dalle variabili s .

Capitolo 4

Algoritmi euristici

4.1 Semplificazione del modello

4.2 Aggregamento dei time-slot

Bibliografia

- [1] Alberto Ceselli, Marco Fiore, Marco Premoli, and Stefano Secci. Optimized assignment patterns in mobile edge cloud networks. *Computers & Operations Research*, 106:246–259, 2019.
- [2] Alberto Ceselli, Marco Fiore, Angelo Furno, Marco Premoli, Stefano Secci, and Razvan Stanica. Prescriptive analytics for mec orchestration. In *2018 IFIP Networking Conference (IFIP Networking) and Workshops*, pages 1–9, 2018.